

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



ĐỒ ÁN KẾT THÚC HỌC PHẦN

MÔN HỌC: XỬ LÝ SỐ LIỆU THỐNG KÊ

TÊN ĐỀ TÀI: SPORTS DATA ANALYSIS

GVHD: TS.Tô Đức Khánh

Thành viên thực hiện:

Nguyễn Phạm Anh Trí - 22110236

Hoàng Minh Hiền - 22280021

Bạch Ngọc Lê Duy - 22280016

Hoàng Thái Hoàng - 22280028

Hồng Đức Hoàng - 22280029

Lê Tuấn Minh Thành - 22280083

Tp. Hồ Chí Minh, tháng 01 năm 2025

MỤC LỤC

I. Giới thiệu

- 1. Đề tài**
- 2. Bộ dữ liệu**
- 3. Vai trò**

II. Tiền xử lý dữ liệu

- 1. Chuyển đổi định dạng và loại bỏ dữ liệu không cần thiết.**
- 2. Kiểm tra và xử lý dữ liệu khuyết**
- 3. Kiểm tra dữ liệu sau xử lý**

III. Khám phá dữ liệu (EDA)

- 1. Phân phối các thuộc tính chính**
- 2. Phân tích mối quan hệ giữa các biến**
- 3. Phân nhóm và xử lý dữ liệu**
- 4. Ma trận tương quan**

IV. Xây dựng bài toán

- 1. Bài toán dự đoán giá tiền chuyển nhượng cầu thủ (Value) mà câu lạc bộ phải chi trả**
- 2. Dự đoán vị trí cầu thủ**
- 3. Dự đoán overall các biến chỉ số kỹ thuật- theo từng vị trí.**
- 4. Dự đoán sự tiềm năng của cầu thủ**

V. Phần kết

I. Giới thiệu

1. Đề tài

Sports Data Analysis là lĩnh vực sử dụng các phương pháp phân tích dữ liệu, thống kê và học máy để khám phá, phân tích và tối ưu hóa các khía cạnh khác nhau trong thể thao. Từ việc đánh giá hiệu suất cầu thủ, chiến thuật thi đấu, đến tối ưu hóa ngân sách chuyển nhượng, lĩnh vực này ngày càng đóng vai trò quan trọng trong việc ra quyết định dựa trên dữ liệu.

Một ví dụ điển hình trong lĩnh vực này là việc phân tích dữ liệu cầu thủ bóng đá để hỗ trợ các câu lạc bộ xây dựng chiến lược mua sắm cầu thủ hợp lý. Nghiên cứu này tập trung vào việc đánh giá cầu thủ dựa trên các yếu tố như **tuổi, quốc tịch, mức lương, hiệu suất thi đấu, và giá trị thị trường**.

2. Bộ dữ liệu

Dữ liệu được sử dụng trong dự án là **FIFA Player Stats**, được tổng hợp từ trò chơi nổi tiếng **FIFA**, chứa thông tin chi tiết của hơn 18.000 cầu thủ bóng đá trên toàn thế giới. Dataset này thường được sử dụng trong các nghiên cứu và phân tích liên quan đến thể thao, quản lý đội bóng và dự đoán hiệu suất.

Số biến: 57, bao gồm: **Thông tin cơ bản:** ID, tên, tuổi, quốc tịch, câu lạc bộ.

Đánh giá hiệu suất: Điểm tổng thể (*Overall*), tiềm năng (*Potential*), vị trí (*Position*). **Thông tin tài chính:** Giá trị thị trường (*Value*), tiền lương (*Wage*), điều khoản giải phóng (*Release.Clause*). **Đặc điểm cá nhân:** Chiều cao (*Height*), cân nặng (*Weight*), chân thuận (*Preferred.Foot*). Và các **chỉ số đánh giá kỹ thuật** khác.

3. Vai trò

Phân tích dữ liệu cầu thủ cung cấp thông tin quan trọng cho:

- **Ban quản lý đội bóng:** Xác định cầu thủ phù hợp với ngân sách và chiến lược của đội.
- **Huấn luyện viên:** Đánh giá hiệu suất thực tế và tiềm năng để bố trí đội hình tối ưu.
- **Các nhà phân tích:** Tìm hiểu sâu hơn về sự phát triển và phong độ cầu thủ.

Với môn học Xử lý số liệu thống kê, việc thực hiện đề tài trên dataset này giúp chúng em:

- Ứng dụng các kỹ thuật tiền xử lý dữ liệu, như xử lý dữ liệu sai định dạng hoặc thiếu...

- Sử dụng các phương pháp thống kê và lập trình trong R để phân tích, trực quan hóa và diễn giải kết quả.
- Cải thiện kỹ năng ra quyết định dựa trên dữ liệu.
- Và đặc biệt hơn là khả năng tự đưa ra bài toán để giải quyết, điều mà trước đây chưa hề có trong bất kỳ môn học nào chúng em từng học.

II. Tiền xử lý dữ liệu

1. Chuyển đổi định dạng và loại bỏ dữ liệu không cần thiết.

a. Chuyển đổi định dạng

Dữ liệu trong các cột như value, wage, và release_clause hiện tại được lưu trữ dưới dạng chuỗi với các ký hiệu đặc biệt như €, M (triệu), và K (nghìn), khiến việc thực hiện phép toán hoặc phân tích trở nên khó khăn. Để dễ dàng thực hiện các phép toán, so sánh giá trị, và sử dụng trong các mô hình phân tích, các giá trị này cần được chuyển đổi sang định dạng số.

- o Ký hiệu € được loại bỏ.
- o Ký hiệu M được thay bằng 1e6 (1 triệu).
- o Ký hiệu K được thay bằng 1e3 (1 nghìn).

Ngoài ra, dữ liệu về chiều cao và cân nặng (ví dụ: height: 5'7, weight: 159lbs) hiện tại được lưu trữ dưới dạng văn bản, không phù hợp với các phương pháp phân tích hoặc thống kê. Việc chuyển đổi các giá trị này sang dạng số giúp chuẩn hóa dữ liệu, đồng thời hỗ trợ việc phân tích và trực quan hóa dễ dàng hơn.


b. Loại bỏ dữ liệu không cần thiết.

Để tập trung vào các thuộc tính quan trọng, giảm tải kích thước và tăng hiệu quả xử lý, cần loại bỏ những cột dữ liệu không cung cấp giá trị thông tin cho phân tích. Các cột như loaned_from, id, jersey_number, và joined không có tác dụng trong quá trình phân tích và có thể làm phức tạp dữ liệu, vì vậy chúng cần được loại bỏ khỏi bộ dữ liệu. Kiểm tra và xử lý dữ liệu khuyết

2. Kiểm tra và xử lý dữ liệu khuyết.

- **Kiểm tra giá trị thiếu:** Dựa vào kết quả kiểm tra, ta nhận thấy rằng phần lớn các cột trong bộ dữ liệu không có giá trị thiếu, ngoại trừ một số cột. Tuy nhiên, có một số cột có tỷ lệ giá trị thiếu đáng kể. Cụ thể:
 - + Cột club có 241 giá trị thiếu.

- + Các cột preferred_foot, international_reputation, weak_foot, skill_moves có 48 giá trị thiếu mỗi cột.
 - + Các cột work_rate, body_type, position, contract_valid_until, height, weight cũng có giá trị thiếu, với số lượng dao động từ 48 đến 289.
 - + Các cột về chỉ số kỹ thuật như crossing, finishing, heading_accuracy, short_passing, volleys, dribbling... đều có 48 giá trị thiếu mỗi cột.
 - + Cột release_clause có 1564 giá trị thiếu.
- **Kiểm tra xu hướng dữ liệu khuyết:** Để hiểu rõ hơn về phân bố và xu hướng của dữ liệu khuyết, chúng tôi đã sử dụng công cụ trực quan hóa để thể hiện tỷ lệ và mẫu dữ liệu thiếu. Qua đó, có thể nhận thấy rằng đa số các cột có tỷ lệ dữ liệu thiếu rất nhỏ, mặc dù cột release_clause có tỷ lệ thiếu cao hơn so với các cột khác nhưng vẫn dưới 0.09. Điều này cho thấy dữ liệu khuyết không chiếm tỷ lệ quá lớn và đa phần các cột có tỷ lệ khuyết tương tự nhau, cho phép chúng tôi xem xét phương án loại bỏ các dòng chứa giá trị thiếu mà không ảnh hưởng nhiều đến tính đại diện của bộ dữ liệu.



- **Xử lý giá trị thiếu:** Sau khi đánh giá, chúng tôi đã quyết định loại bỏ tất cả các dòng chứa giá trị thiếu bằng cách sử dụng hàm na.omit(). Phương

pháp này giúp làm sạch bộ dữ liệu, đảm bảo rằng bộ dữ liệu chuẩn bị cho các phân tích và mô hình học máy không gặp phải vấn đề thiếu dữ liệu, từ đó nâng cao độ chính xác và hiệu quả trong quá trình xử lý.


3. Kiểm tra dữ liệu sau xử lý.

Sau khi loại bỏ các dòng chứa giá trị thiếu, chúng tôi đã tiến hành kiểm tra lại bộ dữ liệu và xác nhận rằng không còn giá trị thiếu nào tồn tại. Bộ dữ liệu giờ đây đã hoàn chỉnh.

III. Khám phá dữ liệu

1. Phân phối các thuộc tính chính

a. Phân phối Overall Ratings



Nhận xét:

Phân phối điểm số của các cầu thủ gần giống với phân phối chuẩn. Điều này có nghĩa là phần lớn các cầu thủ có điểm số tập trung quanh giá trị trung bình, trong khi số lượng cầu thủ có điểm quá cao hoặc quá thấp giảm dần khi càng xa trung bình. Phân phối này cho thấy hệ thống đánh giá có sự ổn định và tính khách quan.

Ý nghĩa và Ứng dụng:


- **Phân loại cầu thủ:** Phân chia cầu thủ thành các nhóm dựa trên điểm số, từ đó tối ưu hóa việc quản lý và tuyển chọn.

- **Dự đoán hiệu suất:** Xây dựng các mô hình dự đoán điểm số dựa trên yếu tố như vị trí thi đấu, tuổi tác, quốc tịch.
- **So sánh và phân tích:** So sánh hiệu suất giữa các nhóm cầu thủ hoặc phân tích các yếu tố ảnh hưởng đến thành tích cá nhân.

Kết luận:

Sự xuất hiện của phân phối chuẩn trong dữ liệu đánh giá cầu thủ là một tín hiệu tích cực, không chỉ khẳng định tính khách quan của hệ thống đánh giá, đồng thời tạo cơ sở vững chắc cho các phân tích chuyên sâu và chiến lược phát triển dài hạn.

b. Phân phối Potential Ratings



Nhận xét:

Phân phối của điểm tiềm năng cầu thủ gần như tuân theo phân phối chuẩn. Điều này có nghĩa là phần lớn các cầu thủ có điểm tiềm năng tập trung quanh giá trị trung bình, và số lượng cầu thủ có điểm tiềm năng quá cao hoặc quá thấp giảm dần khi xa khỏi giá trị trung bình. Hình dạng của biểu đồ cũng cho thấy sự đối xứng tương đối quanh giá trị trung bình.

Ý nghĩa và Ứng dụng:


- **Đánh giá tiềm năng cầu thủ:** Xác nhận rằng hệ thống đánh giá tiềm năng của cầu thủ ổn định và khách quan.

- **Phân loại cầu thủ:** Có thể sử dụng phân phối này để phân loại cầu thủ thành các nhóm dựa trên điểm tiềm năng, ví dụ: cầu thủ tiềm năng cao, trung bình, thấp.
- **Dự đoán:** Các mô hình dự đoán điểm tiềm năng trong tương lai có thể được xây dựng dựa trên yếu tố như tuổi, vị trí thi đấu, quốc tịch.
- **So sánh:** So sánh điểm tiềm năng của các nhóm cầu thủ như tiền đạo, hậu vệ để phát hiện sự khác biệt nổi bật.

Kết luận:

Phân tích biểu đồ cho thấy điểm tiềm năng của các cầu thủ phân bố theo một quy luật khá ổn định, tập trung quanh một giá trị trung bình. Điều này cung cấp một nền tảng vững chắc để đánh giá, so sánh và dự đoán tiềm năng của cầu thủ. Việc hiểu rõ phân phối này giúp các nhà quản lý bóng đá, các nhà tuyển chọn và các nhà đầu tư có cái nhìn sâu sắc hơn về thị trường cầu thủ, từ đó đưa ra những quyết định chính xác hơn.

c. Phân phối Values



Nhận xét:

Biểu đồ phân phối của giá trị có dạng lệch phải (right-skewed), với phần lớn giá trị tập trung ở phía thấp và một số ít giá trị rất cao. Điều này cho thấy phần lớn các đối tượng trong tập dữ liệu có giá trị nhỏ, trong khi một số ít đối tượng có giá trị rất lớn. Giá trị trung bình của dữ liệu có thể bị kéo lệch về phía phải do sự hiện diện của các giá trị ngoại lệ lớn.


Ý nghĩa và Ứng dụng

- **Hiểu rõ về dữ liệu:** Biểu đồ giúp hiểu rõ sự phân bố của giá trị trong tập dữ liệu, từ đó đưa ra quyết định phù hợp trong phân tích và xử lý.
- **Phát hiện giá trị ngoại lệ:** Các giá trị ngoại lệ nằm xa so với phần lớn các giá trị khác, thể hiện ở phần đuôi bên phải của biểu đồ.
- **Chọn mô hình phân phối:** Dựa trên hình dạng của biểu đồ, chúng ta có thể chọn mô hình phân phối phù hợp để mô tả dữ liệu.
- **Tiền xử lý dữ liệu:** Tùy thuộc vào mục tiêu của phân tích, chúng ta có thể cần thực hiện các biện pháp tiền xử lý dữ liệu như:
 - + **Loại bỏ giá trị ngoại lệ:** Nếu các giá trị ngoại lệ ảnh hưởng đáng kể đến kết quả phân tích, chúng ta có thể loại bỏ chúng.
 - + **Biến đổi dữ liệu:** Sử dụng các phép biến đổi như logarit để làm giảm độ lệch của dữ liệu.
 - + **Chia dữ liệu:** Chia dữ liệu thành các nhóm nhỏ hơn để phân tích chi tiết hơn.

Kết luận

Phân phối lệch phải chỉ ra rằng phần lớn dữ liệu có giá trị nhỏ, nhưng có một số ít giá trị rất lớn. Hiểu rõ đặc điểm này giúp chọn phương pháp thống kê và mô hình phân tích phù hợp, đồng thời hỗ trợ tiền xử lý dữ liệu hiệu quả.

d. Phân phối số lượng theo vị trí (Position)



Nhận xét:

Biểu đồ cột cho thấy sự phân bố không đồng đều của cầu thủ ở các vị trí trên sân. Các vị trí như CAM, CB, và GK có số lượng cầu thủ nhiều, trong khi các vị trí như LS, LW lại ít. Điều này phản ánh nhu cầu cầu thủ ở các vị trí khác nhau không đồng đều.


Ý nghĩa và Ứng dụng

- **Hiểu rõ về cấu trúc đội hình:** Biểu đồ giúp chúng ta hiểu rõ về cấu trúc đội hình điển hình trong tập dữ liệu.
- **Phân tích chiến thuật:** Có thể so sánh phân bố vị trí giữa các đội bóng khác nhau để tìm ra những điểm khác biệt về chiến thuật.
- **Đánh giá thị trường chuyển nhượng:** Biểu đồ có thể cung cấp thông tin về nhu cầu cầu thủ ở các vị trí khác nhau, từ đó hỗ trợ các quyết định chuyển nhượng.
- **Phân tích hiệu suất:** Có thể kết hợp biểu đồ này với các dữ liệu khác về hiệu suất của cầu thủ để đánh giá hiệu quả của từng vị trí.

Kết luận

Biểu đồ phân bố vị trí cầu thủ cung cấp một cái nhìn tổng quan về cấu trúc đội hình và sự phân bố cầu thủ ở các vị trí khác nhau. Thông qua việc phân tích biểu đồ này, chúng ta có thể hiểu rõ hơn về sự cân bằng đội hình, các xu hướng chiến thuật hiện đại, và từ đó đưa ra các quyết định hợp lý trong việc xây dựng và quản lý đội bóng.

e. Phân phối theo Body Type



Nhận xét:

Sự phân bố không đồng đều giữa các loại hình thể của cầu thủ, với một số loại có nhiều cầu thủ, trong khi các loại khác lại ít.

Ý nghĩa và Ứng dụng


- **Hiểu rõ về đặc điểm thể hình của cầu thủ:** Biểu đồ giúp chúng ta hiểu rõ hơn về sự đa dạng về hình thể của các cầu thủ, từ đó có thể phân tích mối quan hệ giữa hình thể và vị trí thi đấu, hiệu suất thi đấu.
- **Phân tích chiến thuật:** Hỗ trợ xây dựng đội hình với sự kết hợp thể hình hợp lý, tối ưu hiệu suất thi đấu.
- **Tuyển chọn cầu thủ:** Các nhà tuyển chọn có thể sử dụng biểu đồ này để xác định những loại hình thể mà đội bóng cần bổ sung và tìm kiếm những cầu thủ phù hợp.

Kết luận

Biểu đồ phân bố thể hình cầu thủ cung cấp một cái nhìn tổng quan về sự đa dạng về hình thể của các cầu thủ trong một nhóm dữ liệu cụ thể. Thông qua việc phân tích biểu đồ này, chúng ta có thể hiểu rõ hơn về mối quan hệ giữa hình thể và hiệu suất thi đấu, từ đó đưa ra những quyết định chính xác hơn trong việc xây dựng đội hình và phát triển cầu thủ.

2. Phân nhóm và xử lý dữ liệu

Phân loại cầu thủ theo liên đoàn bóng đá: Mục tiêu của phân tích này là phân loại các cầu thủ bóng đá theo các liên đoàn quốc tế như UEFA, CONMEBOL, CONCACAF, CAF, AFC và OFC. Dữ liệu quốc tịch của cầu thủ được sử dụng để xác định liên đoàn mà họ thuộc về, với những quốc gia không thuộc nhóm nào sẽ được xếp vào "Other". Sau khi phân loại, số lượng cầu thủ của mỗi liên đoàn được thống kê và thể hiện qua biểu đồ cột.



Nhận xét:

Biểu đồ cho thấy sự chênh lệch rõ rệt giữa các liên đoàn, với UEFA chiếm ưu thế vượt trội về số lượng cầu thủ, phản ánh sự thống trị của bóng đá châu Âu. Các liên đoàn khác như CONMEBOL, CONCACAF và CAF đóng góp đáng kể nhưng vẫn kém xa so với UEFA. Các liên đoàn nhỏ như OFC và Other có số lượng cầu thủ ít hơn, cho thấy sự khác biệt về quy mô và ảnh hưởng bóng đá giữa các khu vực.

Ý nghĩa và Ứng dụng

- Hiểu rõ sự phân bố cầu thủ toàn cầu:** Biểu đồ giúp chúng ta hình dung rõ hơn về sự phân bố cầu thủ trên toàn thế giới và tầm ảnh hưởng của các liên đoàn bóng đá khác nhau.


- **Phân tích thị trường chuyển nhượng:** Các câu lạc bộ và các nhà quản lý có thể sử dụng thông tin này để đánh giá tiềm năng của thị trường chuyển nhượng ở các khu vực khác nhau.
- **So sánh trình độ:** Việc so sánh số lượng cầu thủ giữa các liên đoàn có thể giúp chúng ta đánh giá một cách tương đối về trình độ bóng đá của các khu vực.
- **Phát triển bóng đá:** Các liên đoàn bóng đá có thể sử dụng thông tin này để xác định những điểm mạnh và điểm yếu, từ đó đưa ra các chiến lược phát triển phù hợp.

Kết luận

Biểu đồ phân bố cầu thủ theo liên đoàn bóng đá cung cấp một cái nhìn tổng quan về sự đa dạng và sự phân bố không đồng đều của cầu thủ trên toàn thế giới. UEFA nổi lên như một thế lực thống trị, trong khi các liên đoàn khác cũng đóng góp một phần quan trọng vào sự phát triển của bóng đá. Việc hiểu rõ sự phân bố này sẽ giúp chúng ta đánh giá đúng vai trò và tầm quan trọng của từng liên đoàn bóng đá, từ đó đưa ra những quyết định chiến lược phù hợp.

3. Phân tích mối quan hệ giữa các biến

a. Mối quan hệ giữa Potential và Value



Nhận xét:

Biểu đồ thể hiện mối quan hệ tương quan dương giữa tiềm năng và giá trị cầu thủ: khi tiềm năng tăng, giá trị cũng có xu hướng tăng theo. Tuy nhiên, mối quan hệ này không hoàn toàn tuyến tính và chịu ảnh hưởng của nhiều yếu tố khác, với một số điểm ngoại lệ, phản ánh những cầu thủ có giá trị không tương xứng với tiềm năng.


Ý nghĩa và Ứng dụng

- **Đánh giá cầu thủ:** Biểu đồ giúp chúng ta đánh giá một cách khách quan về mối quan hệ giữa tiềm năng và giá trị của cầu thủ.
- **Quyết định chuyển nhượng:** Các câu lạc bộ có thể sử dụng biểu đồ này để đánh giá xem giá trị chuyển nhượng của một cầu thủ có phù hợp với tiềm năng của họ hay không.
- **Xây dựng chiến lược chuyển nhượng:** Biểu đồ giúp các câu lạc bộ xác định những cầu thủ có tiềm năng cao nhưng giá trị chưa được đánh giá đúng mức để đầu tư.
- **Nghiên cứu thị trường chuyển nhượng:** Biểu đồ có thể được sử dụng để phân tích thị trường chuyển nhượng, tìm ra các xu hướng và quy luật.

Kết luận

Biểu đồ mối quan hệ giữa Potential và Value cung cấp một cái nhìn tổng quan về mối liên hệ giữa tiềm năng và giá trị của cầu thủ. Mặc dù có xu hướng tương quan dương rõ ràng giữa hai biến số này, nhưng vẫn có nhiều yếu tố khác ảnh hưởng đến giá trị của cầu thủ. Việc hiểu rõ mối quan hệ này sẽ giúp các nhà quản lý bóng đá, các nhà đầu tư và các nhà phân tích đưa ra những quyết định chính xác hơn trong việc đánh giá và chuyển nhượng cầu thủ.

b. Mối quan hệ giữa Potential và Age



Nhận xét:

Biểu đồ cho thấy mối quan hệ không hoàn toàn tuyến tính giữa tiềm năng và tuổi. Dù cầu thủ trẻ thường có tiềm năng cao hơn, nhưng tài năng và nỗ lực cá nhân mới là yếu tố quyết định. Tuổi không phải là rào cản phát triển sự nghiệp cầu thủ.

Ý nghĩa và Ứng dụng

- **Đánh giá tiềm năng cầu thủ:** Biểu đồ cho thấy tuổi tác không phải là yếu tố quyết định duy nhất về tiềm năng của cầu thủ. Tài năng và sự nỗ lực cá nhân cũng đóng vai trò quan trọng.
- **Tuyển chọn cầu thủ:** Giúp các câu lạc bộ nhận diện cầu thủ trẻ có tiềm năng phát triển.
- **Quản lý sự nghiệp cầu thủ:** Biểu đồ giúp các cầu thủ và các nhà quản lý hiểu rõ hơn về quá trình phát triển sự nghiệp của cầu thủ và đưa ra những quyết định phù hợp.


Kết luận

Biểu đồ mối quan hệ giữa tiềm năng và tuổi cho thấy rằng tiềm năng của cầu thủ không chỉ phụ thuộc vào tuổi tác mà còn chịu ảnh hưởng bởi

nhiều yếu tố khác. Việc hiểu rõ mối quan hệ này sẽ giúp các nhà quản lý bóng đá, các nhà tuyển chọn và các nhà khoa học đưa ra những quyết định chính xác hơn trong việc đánh giá và phát triển cầu thủ.

4. Ma trận tương quan

a. Ma trận tương quan giữa các biến chính



Nhận xét:

Biểu đồ ma trận tương quan cho thấy mối liên hệ chặt chẽ giữa các thuộc tính của cầu thủ bóng đá. Cụ thể:

- **Giá trị và tiềm năng:** Cầu thủ càng có tiềm năng cao, cầu thủ càng có giá trị lớn, mức lương cao và phí giải phóng hợp đồng cao. Điều này hợp lý vì các đội bóng thường sẵn sàng đầu tư nhiều hơn cho những cầu thủ có triển vọng phát triển.
- **Tuổi tác và tiềm năng:** Cầu thủ trẻ thường có tiềm năng phát triển cao hơn so với cầu thủ lớn tuổi. Tuy nhiên, điều này không có nghĩa là cầu thủ lớn tuổi không thể có tiềm năng.
- **Các yếu tố khác:** Ngoài tiềm năng và tuổi tác, các yếu tố như vị trí thi đấu, quốc tịch, kinh nghiệm thi đấu cũng ảnh hưởng đến giá trị của cầu thủ, nhưng biểu đồ này chưa thể hiện rõ mối quan hệ đó.


Ý nghĩa và ứng dụng:

- **Hiểu rõ mối quan hệ giữa các thuộc tính:** Biểu đồ giúp chúng ta hiểu rõ hơn về mối liên hệ giữa các đặc điểm khác nhau của cầu thủ, từ đó đưa ra những nhận định và quyết định chính xác hơn.
- **Xây dựng mô hình dự đoán:** Có thể dùng thông tin để dự đoán giá trị cầu thủ, tiềm năng phát triển và phân loại cầu thủ.
- **Tuyển chọn cầu thủ:** Các nhà tuyển chọn có thể sử dụng thông tin này để xác định những cầu thủ có tiềm năng cao và phù hợp với yêu cầu của đội bóng.

Kết luận

Biểu đồ ma trận tương quan cung cấp cái nhìn tổng quan về các yếu tố ảnh hưởng đến giá trị cầu thủ, từ đó giúp đưa ra các quyết định chiến lược chính xác trong quản lý và phát triển đội bóng.

b. Ma trận tương quan thông số kỹ thuật (Technical Stats)



Nhận xét:

Biểu đồ ma trận tương quan cho thấy mối liên hệ chặt chẽ giữa các kỹ năng của cầu thủ bóng đá. Một số điểm nổi bật bao gồm:

- **Các nhóm kỹ năng liên kết:** Các kỹ năng như giữ bóng, chuyền bóng, dứt điểm có mối liên hệ chặt chẽ với nhau. Tương tự, các kỹ năng phòng ngự cũng có mối tương quan cao.

- **Tương quan giữa các nhóm kỹ năng:** Các nhóm kỹ năng tấn công và phòng ngự thường có mối tương quan âm, nghĩa là việc tập trung phát triển một nhóm kỹ năng có thể ảnh hưởng đến các nhóm kỹ năng khác.
- **Các kỹ năng độc lập:** Một số kỹ năng như thể lực, chiều cao có thể không có mối liên hệ chặt chẽ với các kỹ năng kỹ thuật khác.

IV. Xây dựng bài toán

1. Bài toán dự đoán giá trị chuyển nhượng cầu thủ (Value) mà câu lạc bộ phải chi trả

Trong bài toán này, mục tiêu là dự đoán giá trị chuyển nhượng (Value) của cầu thủ, tức là số tiền mà câu lạc bộ cần phải chi trả để sở hữu cầu thủ đó. Để thực hiện dự đoán này, nhóm sử dụng các mô hình học máy để phân tích các yếu tố ảnh hưởng đến giá trị của cầu thủ. Các yếu tố này có thể bao gồm các chỉ số kỹ thuật như khả năng chuyền bóng, tốc độ, sức mạnh, cũng như các yếu tố phi kỹ thuật như độ tuổi, quốc tịch, mức lương, và vị trí thi đấu,...

Để tiếp cận bài toán một cách hiệu quả, nhóm em phân chia các biến quan sát thành hai nhóm chính:

- **Biến kỹ thuật (technical):** Là những yếu tố liên quan trực tiếp đến khả năng thi đấu của cầu thủ, chẳng hạn như các chỉ số về kỹ năng, sức mạnh, tốc độ, v.v.
- **Biến phi kỹ thuật (nontechnical):** Bao gồm các yếu tố không liên quan trực tiếp đến kỹ năng thi đấu, ví dụ như thông tin cá nhân (tuổi, quốc tịch), mức lương, và đội bóng hiện tại. Tất nhiên có loại bỏ trước những biến không phù hợp qua đánh giá sơ bộ.

Việc phân chia các biến quan sát thành hai nhóm này giúp chúng ta hiểu rõ hơn về tác động của từng yếu tố đến giá trị chuyển nhượng của cầu thủ. Mỗi nhóm biến sẽ được đưa vào các mô hình hồi quy tuyến tính riêng biệt, giúp chúng ta phân tích sâu hơn về vai trò của các yếu tố kỹ thuật và phi kỹ thuật trong việc định giá cầu thủ.

Lợi ích của cách tiếp cận này bao gồm:

- **Xác định yếu tố ảnh hưởng:** Giúp xác định yếu tố nào (kỹ thuật hay phi kỹ thuật) đóng vai trò quan trọng hơn trong việc quyết định giá trị chuyển nhượng của cầu thủ.

- **Giảm nguy cơ overfitting:** Bằng cách tập trung vào từng nhóm biến quan sát riêng biệt, số lượng biến đầu vào được giảm bớt, từ đó giảm thiểu nguy cơ overfitting.

Kết quả của bài toán này sẽ cung cấp cái nhìn rõ ràng hơn về các yếu tố ảnh hưởng đến giá trị chuyển nhượng của cầu thủ, hỗ trợ các quyết định chiến lược trong việc mua bán và tuyển dụng cầu thủ của câu lạc bộ.

1.1. Cách tiếp cận 1: Sử dụng biến phi kỹ thuật

Mục tiêu: Xây dựng mô hình dự đoán giá trị chuyển nhượng của cầu thủ dựa trên các yếu tố phi kỹ thuật.

Phương pháp:

Lựa chọn biến đầu vào: Các biến phi kỹ thuật bao gồm age, overall, potential, wage, international_reputation và release_clause. Vì overall và potential có khả năng tương quan cao (dựa vào heatmap của ma trận hệ số tương quan) nên ta chỉ chọn 1 biến là overall vào mô hình để tránh hiện tượng đa cộng tuyến.

Xây dựng mô hình: Sử dụng mô hình hồi quy tuyến tính với biến mục tiêu là value (giá trị chuyển nhượng), các biến quan sát gồm age, overall, wage, international_reputation và release_clause.

```
m_value_non_tech = lm(value ~ age + overall + wage + international_reputation
+ release_clause, fifa_data)
```

Lựa chọn tập biến tốt nhất: Sử dụng chỉ số Mallows' Cp để tìm ra tập biến con tốt nhất cho mô hình. Tập biến tốt nhất là tập bao gồm 4 biến trên với Cp bằng 4.05

```
1 subsets of each size up to 5
Selection Algorithm: exhaustive
      age overall wage international_reputation release_clause
1 ( 1 ) " " " " " " " " " "
2 ( 1 ) " " " " " " " " " "
3 ( 1 ) " " " " " " " " " "
4 ( 1 ) " " " " " " " " " "
5 ( 1 ) " " " " " " " " " "
[1] 1768.172387 639.163879 212.815508 4.058525 6.000000
```

Ta xây dựng lại mô hình với 4 biến overall, wage, international_reputation và release_clause

```
m_value_non_tech = lm(value ~ overall + wage + international_reputation
+ release_clause, fifa_data)
```


Các chỉ số của mô hình

SSE: 5.544407e+15
MSE: 333137488534
RMSE: 577180.6
R-squared: 0.9898197
RSE: 30398485

Hệ số R-squared = 0.9898, cho thấy mô hình giải thích được 98.98% biến thiên trong giá trị chuyển nhượng.


Chẩn đoán cho mô hình:

Kiểm tra tính tuyến tính: Ta sử dụng biểu đồ Residual - Fitted để kiểm tra tính tuyến tính của mô hình.




- Các điểm màu đen (phần dư) không hoàn toàn phân bố ngẫu nhiên xung quanh đường $y = 0$, hơn nữa mức độ biến động của chúng càng tăng khi giá trị dự đoán tăng dần.
- Đường màu xanh không hoàn toàn khớp với đường nét đứt ($y = 0$) mà có xu hướng cong nhẹ ở vùng có giá trị dự đoán cao. Điều này cho thấy rằng có thể tồn tại mối quan hệ phi tuyến giữa biến mục tiêu và một vài biến quan sát trong mô hình.
- Do đó giả định về tính tuyến tính của mô hình là chưa phù hợp.

Kiểm tra tính đồng nhất phương sai: Ta sử dụng biểu đồ thặng dư chuẩn hóa để kiểm tra tính đồng nhất phương sai



- Phần dư chuẩn hóa (đường màu xanh) có xu hướng đi lên khi giá trị dự đoán tăng. Điều này là minh chứng cho hiện tượng heteroskedasticity (phương sai thay đổi) vì phương sai phần dư không đồng nhất mà tăng dần theo giá trị dự đoán.

Kiểm tra các giá trị ngoại lai: Sử dụng thông số Cook's distance để đánh giá các điểm dữ liệu có tiềm năng ảnh hưởng lớn đến mô hình



Ta thực hiện tính toán để xem các điểm có Cook's distance ≥ 2.5 chiếm bao nhiêu phần trăm tổng dữ liệu:

```
Phần trăm của dữ liệu có Cook's Distance  $\geq 0.5$  là: 0.02403413 %  
Phần trăm của dữ liệu có Cook's Distance  $\geq 1.0$  là: 0.01201706 %  
Phần trăm của dữ liệu có Cook's Distance  $\geq 1.5$  là: 0.006008532 %
```

Các điểm có Cook's Distance ≥ 0.5 chỉ chiếm khoảng 0.02% tổng dữ liệu. Do đó chúng không ảnh hưởng đáng kể đến mô hình.

Kiểm tra hiện tượng đa cộng tuyến: Sử dụng chỉ số Vif để kiểm tra độ tương quan giữa các biến độc lập trong mô hình hồi quy

overall
1.672385

wage international_reputation
4.197567 1.943834

release_clause
4.148991

Chỉ số Vif cho 5 biến trên đều nhỏ hơn 5. Chứng tỏ không xảy ra hiện tượng đa cộng tuyến trong mô hình


Mở rộng mô hình:

- Lý do mở rộng: Trong phần chẩn đoán, ta thấy được rằng giả định về tính tuyến tính của mô hình là không phù hợp và mô hình không đồng nhất phương sai. Do đó ta sẽ mở rộng mô hình để giải quyết 2 vấn đề đó.
- Phương pháp mở rộng: Generalized Linear Model (GLM) và Generalized Additive Model (GAM)

Phương pháp GLM:

Mô hình này sử dụng phân phối Gamma để mô hình hóa cho dữ liệu bị lệch phải giúp tránh được hiện tượng phương sai không đồng nhất và giá trị lớn trong dữ liệu của biến phản hồi.

Ta xem xét phân phối của Value:



Dễ dàng thấy rằng dữ liệu của Value bị lệch phải rất nhiều, phù hợp để áp dụng GLM

Triển khai mô hình GLM

Bước 1: Kiểm tra các giá trị âm và giá trị 0 trong mô hình

Vì phân phối Gamma không chấp nhận các giá trị bé hơn hoặc bằng 0 nên ta xét xem chúng chiếm bao nhiêu phần trăm trong tổng dữ liệu

Phần trăm các giá trị bé hơn hoặc bằng 0 trong biến value là: 0 %

Bởi vì không tồn tại các giá trị có value bằng 0 nên ta có thể áp dụng mô hình GLM

Bước 2: Xây dựng mô hình GLM

```
Call:
glm(formula = value ~ overall + wage + international_reputation +
     release_clause, family = Gamma(link = "log"), data = fifa_data)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.318e+00	3.235e-02	71.64	<2e-16	***
overall	1.740e-01	5.019e-04	346.64	<2e-16	***
wage	-2.801e-06	2.503e-07	-11.19	<2e-16	***
international_reputation	-2.405e-01	9.514e-03	-25.27	<2e-16	***
release_clause	3.126e-08	4.983e-10	62.74	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Gamma family taken to be 0.1231074)

Null deviance: 37127.5 on 16642 degrees of freedom
 Residual deviance: 2773.8 on 16638 degrees of freedom
 AIC: 470347

Number of Fisher Scoring iterations: 14


Bước 3: Nhận xét

- Nhìn chung các biến đều có p-value rất thấp, đồng nghĩa với việc chúng có ý nghĩa thống kê.
- Các biến wage và release_clause có hệ số nhỏ cho thấy ảnh hưởng thực tế của chúng lên value có thể không đáng kể. Overall và international_reputation có hệ số khá lớn nên chúng ảnh hưởng đáng kể lên value.
- Dispersion parameter for Gamma family: Đây là tham số cho biết mức độ phân tán của phân phối Gamma, giá trị xấp xỉ 0.123 cho thấy độ phân tán không quá lớn, nên mô hình phù hợp với dữ liệu
- Null deviance: (trên 17954 bậc tự do): Đây là tham số đo độ lệch giữa mô hình chỉ với hệ số chặn và mô hình có đầy đủ hệ số. Giá trị 37127.5 chứng tỏ mô hình với đầy đủ hệ số đã cải thiện tốt hơn so với mô hình chỉ với một hệ số chặn
- Residual deviance (trên 17949 bậc tự do): Là độ lệch của mô hình với tất cả các biến độc lập đã được đưa vào. Giá trị 2773.8 là một giá trị thấp hơn rất nhiều so với null deviance, cho thấy mô hình đầy đủ có khả năng giải thích tốt dữ liệu.
- AIC (Akaike Information Criterion): Là chỉ số dùng để so sánh giữa các mô hình với nhau. Mô hình có AIC thấp hơn được coi là tốt hơn.

- Number of Fisher Scoring iterations: Đây là số lần thuật toán Fisher Scoring (phương pháp tối ưu hóa được sử dụng trong GLM) lặp lại để hội tụ. Mô hình cho thấy thuật toán đã hội tụ nhanh chóng sau 14 lần lặp.

Bước 4: Đánh giá

- Mặc dù các tham số trên cho ta một cái nhìn lạc quan về mô hình nhưng ta cần kiểm tra lại các giả định một lần nữa bằng biểu đồ Residual - fitted





- Ta thấy rằng phần dư trong biểu đồ trên giảm dần theo chiều tăng của giá trị dự đoán. Điều này là dấu hiệu cho thấy sự mất đồng nhất phương sai. Nếu vấn đề mất đồng nhất phương sai còn tồn tại, mô hình có thể không ước lượng chính xác, dẫn đến các sai số chuẩn không chính xác và các kết quả không đáng tin cậy.
- Biểu đồ residual - fitted chỉ ra rằng mô hình GLM hiện tại có lẽ không phù hợp với dữ liệu. Điều này có thể do mô hình chưa giải thích được toàn bộ sự biến thiên trong dữ liệu.



Phương pháp GAM:

Mô hình GAM cho phép biểu diễn linh hoạt cả mối quan hệ tuyến tính và phi tuyến giữa các biến độc lập và biến phụ thuộc bằng cách thêm vào các hàm trơn cho một hoặc nhiều biến độc lập.

Ta có thể áp dụng GAM cho toàn bộ biến hoặc cho một hoặc một vài biến trong mô hình. Ở đây mô hình ta có 4 biến, nên ta sẽ áp dụng cách thứ hai bởi vì cách thứ hai đặc biệt hữu dụng trong trường hợp phát hiện ra mối quan hệ giữa biến mục tiêu và biến giải thích là không tuyến tính.

Ta xét biểu đồ thặng dư từng phần cho từng biến





- Ta có thể thấy đối với biến `release_clause`, đường thẳng màu xanh dương khá khớp với đường nét đứt màu xanh lá. Điều này chứng tỏ có tồn tại mối quan hệ tuyến tính giữa nó và `value`.
- Đối với 2 biến `overall` và `international_reputation`, có sự chênh lệch nhẹ giữa đường thẳng màu xanh dương và đường nét đứt màu xanh lá. Suy ra tồn tại mối quan hệ phi tuyến giữa chúng và `value` nên có thể dùng hàm trơn cho 2 biến này.

- Biến wage có đường thẳng màu xanh dương nằm lệch rất lớn so với đường nét đứt màu xanh lá. Điều này gần như khẳng định mối quan hệ giữa wage và value là phi tuyến tính. Ta sẽ áp dụng hàm tron cho biến này.

Thực hiện và đánh giá

```
Family: gaussian
Link function: identity

Formula:
value ~ s(overall) + s(wage) + s(international_reputation, k = 5) +
      release_clause


Parametric coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.163e+05  6.520e+03  48.51  <2e-16 ***
release_clause 4.638e-01  1.080e-03  429.55  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Approximate significance of smooth terms:
              edf Ref.df      F p-value
s(overall)      5.026  5.870 253.61  <2e-16 ***
s(wage)          2.373  2.801  43.79  <2e-16 ***
s(international_reputation) 1.057  1.076  41.25  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Rank: 15/24
R-sq.(adj) =  0.991  Deviance explained = 99.1%
GCV = 3.0013e+11  Scale est. = 2.9994e+11  n = 16643
```

- Nhìn chung tất cả các biến đều có ý nghĩa thống kê vì p-value < 0.05.
- R-sq(adj): Đây là hệ số xác định điều chỉnh (adjusted R-squared), giá trị 0.991 cho thấy rằng mô hình giải thích được khoảng 99.1% sự biến đổi trong dữ liệu.
- Generalized Cross-Validation (GCV): là một thước đo dùng để đánh giá chất lượng mô hình. GCV càng nhỏ thì mô hình càng tốt. Tuy nhiên, giá trị GCV bằng 3.0013e+11 khá lớn, nên ta cần xem xét khả năng bị overfitting.
- Scale est: Đây là ước lượng của phương sai sai số trong mô hình, cho thấy mức độ biến động của dữ liệu mà mô hình chưa giải thích được.

Ta minh họa dạng hàm tron được ước lượng của từng biến trong mô hình



- Ta có thể thấy hệ số ước lượng của các biến (đường nét liền) luôn nằm giữa và không quá xa khoảng tin cậy (2 đường nét đứt). Điều này chứng tỏ mô hình có độ ổn định cao và các kết quả ước lượng đáng tin cậy.

Tiên đoán dựa trên mô hình:

Để tiên đoán dựa trên của mô hình ta chia tập dữ liệu thành 2 tập Train và Test với tỷ lệ 7:3

Sau khi chia 2 tập dữ liệu, ta sử dụng tập dữ liệu Train để mô hình GAM học và dự đoán giá trị trên tập Test.

R-squared: 0.9907223
RMSE: 560051

Giá trị R-squared = 0.9907 cho thấy rằng mô hình giải thích được khoảng 99.07% sự biến đổi trong dữ liệu.

RMSE/Mean: 0.2292785

Dự đoán của mô hình có mức sai số trung bình khá nhỏ so với giá trị trung bình thực tế. Chứng tỏ rằng mô hình dự đoán khá chính xác so với giá trị thực tế.





1.2. Cách tiếp cận 2: Sử dụng biến kỹ thuật

Mục tiêu: Xây dựng 4 mô hình dự đoán giá trị chuyển nhượng của cầu thủ theo từng nhóm vị trí dựa trên các yếu tố kỹ thuật.

Chia data: Trước hết, ta chia tập đầy đủ thành 4 tập gồm các cầu thủ của 4 nhóm vị trí (Goalkeeper – Thủ môn, Defender - Hậu vệ, Midfielder - Tiền vệ, Forward - Tiền đạo)

Phương pháp:

Lựa chọn biến đầu vào: Với từng tập dữ liệu, ta trực quan histogram trung bình của từng biến kỹ thuật để loại bỏ những biến có giá trị thấp (các biến có khoảng giá trị 1-100) trừ skill_moves và weak_foot (vì 2 biến đó có khoảng giá trị từ 1-5), vì các biến đó không định hình được giá trị cầu thủ tại vị trí của họ.



- Ở hai tập Defender và Midfielder thì bỏ cột liên quan tới GK.
- Ở tập goalkeeper, ta bỏ cột từ stamina trở đi.
- Ở tập forward, ta bỏ cột marking trở đi.

Xây dựng mô hình: Sử dụng mô hình hồi quy tuyến tính với biến mục tiêu là value (giá trị chuyển nhượng), các biến quan sát là các biến kỹ thuật đã được lọc ở trước ở từng vị trí.

Kiểm tra đa cộng tuyến (Lựa chọn VIF > 10 cho vi phạm):

[1] "GK VIF values"						
weak_foot	acceleration	sprint_speed	agility	reactions	balance	jumping
1.041981	3.673612	3.586449	1.681994	3.294572	1.531013	1.728547
strength	vision	composure	gk_diving	gk_handling	gk_kicking	gk_positioning
1.224285	1.338197	1.584972	6.604978	4.768843	2.447355	5.451382
gk_reflexes						
6.684658						
[1] "DF VIF values"						
weak_foot	skill_moves	crossing	finishing	heading_accuracy	short_passing	volleys
1.051563	1.832323	4.299406	3.138055	3.329853	5.455222	2.507933
dribbling	curve	long_passing	ball_control	acceleration	sprint_speed	agility
4.959947	3.929371	4.098916	5.831102	5.837426	4.678053	3.430603
reactions	balance	shot_power	jumping	stamina	strength	long_shots
4.045910	2.924272	3.164925	1.337784	1.752626	2.661054	4.250085
aggression	interceptions	positioning	vision	penalties	composure	marking
2.031034	4.687025	3.784772	3.173242	1.931850	3.359628	3.273977
standing_tackle	sliding_tackle	fk_accuracy				
7.647628	6.288200	2.867483				
[1] "MID VIF values"						
weak_foot	skill_moves	crossing	finishing	heading_accuracy	short_passing	volleys
1.102012	2.614663	2.894887	4.004863	2.092212	6.616623	3.180131
dribbling	curve	long_passing	ball_control	acceleration	sprint_speed	agility
6.728076	3.993532	5.358421	7.811416	4.989316	4.083068	2.982823
reactions	balance	shot_power	jumping	stamina	strength	long_shots
3.596728	2.245635	3.405923	1.387162	2.019801	2.498808	4.374658
aggression	interceptions	positioning	vision	penalties	composure	marking
2.694985	6.345301	3.477030	4.302772	2.273049	3.396090	3.179462
standing_tackle	sliding_tackle	fk_accuracy				
12.867305	9.797822	3.250706				
[1] "FW VIF values"						
weak_foot	skill_moves	crossing	finishing	heading_accuracy	short_passing	volleys
1.143486	2.784028	3.599520	4.796826	3.840367	5.662445	3.579595
dribbling	curve	long_passing	ball_control	acceleration	sprint_speed	agility
7.185799	3.621164	3.677483	7.785745	6.448750	5.196960	3.377466
reactions	balance	shot_power	jumping	stamina	strength	long_shots
4.415558	2.676776	3.961378	1.565229	1.632957	2.865603	3.547331
aggression	positioning	vision	penalties	composure	fk_accuracy	
1.890818	5.685132	3.469478	1.983753	4.116023	2.924861	

Ta thấy được các giá trị VIF của từng biến trên từng model:

- Ở mô hình của tiền vệ thì ta thấy biến standing_tackle có VIF > 10 và sliding_tackle ~ 10, điều này có thể giải thích do sự tương quan cao giữa hai biến, nên có thể bỏ biến standing_tackle.
- Ngoài ra không còn biến nào khác bị hiện tượng đa cộng tuyến.

[1] "VIF MID"						
weak_foot	skill_moves	crossing	finishing	heading_accuracy	short_passing	volleys
1.101922	2.614440	2.893754	4.003283	2.090106	6.604697	3.179384
dribbling	curve	long_passing	ball_control	acceleration	sprint_speed	agility
6.724252	3.993068	5.357547	7.788866	4.988341	4.082434	2.982225
reactions	balance	shot_power	jumping	stamina	strength	long_shots
3.591294	2.243820	3.402692	1.384677	2.015916	2.493541	4.373674
aggression	interceptions	positioning	vision	penalties	composure	marking
2.683446	5.558720	3.476920	4.302656	2.272770	3.395920	3.102627
sliding_tackle	fk_accuracy					
4.881689	3.250671					

Đây là VIF của mô hình tiền vệ sau khi loại bỏ standing_tackle. Không còn hiện tượng đa cộng tuyến.

Lựa chọn tập biến tốt nhất: Sử dụng hồi quy từng bước và cross-validation (5-fold).

- Với tập Goalkeeper: 5 biến được chọn.

```
## [1] "vision"          "gk_diving"        "gk_handling"      "gk_positioning"
## [5] "gk_reflexes"
```

- Với tập Defender: 24 biến được chọn.

```
## [1] "weak_foot"      "skill_moves"      "crossing"          "heading_accuracy"
## [5] "volleys"        "dribbling"        "long_passing"      "acceleration"
## [9] "sprint_speed"   "agility"          "reactions"         "balance"
## [13] "shot_power"     "jumping"          "strength"          "long_shots"
## [17] "aggression"     "interceptions"    "positioning"       "vision"
## [21] "composure"      "marking"          "standing_tackle"   "sliding_tackle"
```

- Với tập Midfielder: 23 biến được chọn.

```
## [1] "weak_foot"      "crossing"          "finishing"         "short_passing"
## [5] "volleys"        "dribbling"        "curve"             "ball_control"
## [9] "acceleration"   "sprint_speed"     "agility"           "reactions"
## [13] "jumping"        "stamina"          "strength"          "long_shots"
## [17] "aggression"     "interceptions"    "vision"            "penalties"
## [21] "composure"      "marking"          "fk_accuracy"
```

- Với tập Forward: 5 biến được chọn.

```
## [1] "finishing"      "ball_control"      "acceleration"      "reactions"         "vision"
```

Các chỉ số mô hình:

- Thủ môn:

```
## Test results
## RMSE: 2447594
## R2_score: 0.304802
```

- Hậu vệ:

```
## Test results
## RMSE: 2872353
## R2_score: 0.4637264
```

- Tiền vệ:

```
## Test results
## RMSE: 3628482
## R2_score: 0.47354
```

- Tiền đạo:


```
## Test results
## RMSE: 4625396
## R2_score: 0.3591482
```

Kết luận: Ta có thể thấy các chỉ số R-squared khá thấp (<0.5) và RMSE cao ở cả 4 mô hình. Cho thấy mô hình không dự đoán tốt giá trị cầu thủ tại vị trí của họ.


Chẩn đoán mô hình:

- Kiểm tra tính tuyến tính:


+ Thủ môn:




+ Hậu vệ:



+ Tiền vệ:




+ Tiền đạo:



=> Có thể thấy cả 4 mô hình đều không thỏa tính tuyến tính vì đường màu xanh không có xu hướng tuyến tính.


- **Tính đồng nhất phương sai:**

+ Thủ môn:




+


+ Hậu vệ:



+ Tiền vệ:



+ Tiền đạo:



=> Cũng có thể thấy cả 4 mô hình đều vi phạm tính đồng nhất phương sai vì đường màu xanh cho thấy xu hướng đi lên ở cuối.

Đề xuất: Cải tiến mô hình sử dụng GLM để giải quyết tình trạng vi phạm đồng nhất phương sai. Cần nhắc kiểm tra thêm tuyến tính từng phần của từng mô hình bằng đồ thị thặng dư từng phần và sử dụng mô hình GAM nếu cần thiết.

1.3. Kết luận cho hai cách tiếp cận:

- Cách tiếp cận với các biến *non-technical* cho ra mô hình dự đoán tốt giá trị cầu thủ với R-squared > 0.95 và RMSE đủ thấp, sử dụng ít biến và có

thể tối ưu mô hình hơn bằng GLM và GAM để cho ra kết quả gần nhất có thể so với giá trị thực tế của cầu thủ.

- Cách tiếp cận với chỉ với các biến *technical* sử dụng 4 mô hình cho 4 nhóm vị trí khác nhau cho ra các dự đoán không tốt, các giá trị R-squared dưới 0.5 mặc dù sử dụng nhiều biến; cả 4 mô hình đều không thoả tính tuyến tính lẫn đồng nhất phương sai.

=> Như vậy, cách tiếp cận sử dụng các biến *non-technical* là cách tiếp cận tốt nhất cho bài toán 1 mà ta đang xét.

2. Dự đoán vị trí cầu thủ

Mục tiêu: Phương pháp được thiết kế để hỗ trợ câu lạc bộ bóng đá đưa ra quyết định mua cầu thủ dựa trên khả năng dự đoán chính xác vị trí chơi phù hợp của cầu thủ. Sử dụng mô hình Logistic Regression đa lớp và Naive Bayes. Không chỉ vậy, phần mở rộng của bài toán này còn đánh giá và cho ra các vị trí thay thế khả thi (Top-1, Top-2, Top-3) bằng Logistic Regression đa lớp, từ đó cung cấp cái nhìn tổng quan và sâu sắc về khả năng đa dạng hóa của cầu thủ. Dựa trên kết quả Top-k dự đoán, ban huấn luyện và đội ngũ tuyển dụng có thể xác định mức độ phù hợp của cầu thủ với chiến thuật và vị trí còn thiếu trong đội hình hiện tại. Xác suất nhầm lẫn (Top-1, Top-2, Top-3) cung cấp dữ liệu để cân nhắc mức độ rủi ro và khả năng thích ứng của cầu thủ ở những vị trí không phải là sở trường. Việc mua cầu thủ thường là khoản đầu tư lớn của câu lạc bộ. Phương pháp này cung cấp thêm một lớp phân tích định lượng, giúp giảm thiểu các quyết định sai lầm dựa trên cảm tính hoặc dữ liệu không đầy đủ.

Phương pháp:

- Sử dụng dataset với các đặc trưng kỹ thuật của cầu thủ (trừ thủ môn), bao gồm các thông tin như khả năng sút bóng, chuyền bóng, tốc độ, thể lực, và khả năng phòng ngự.
- Vị trí thực tế của cầu thủ là nhãn mục tiêu cần dự đoán.
- Bao gồm các chỉ số như: crossing, finishing, dribbling, stamina, strength, tackling, và nhiều đặc trưng khác. Đây là các yếu tố được sử dụng làm đầu vào cho mô hình dự đoán.

2.1. Cách tiếp cận cơ bản

Tiền Xử Lý Dữ Liệu:

- Loại bỏ class thủ môn - GK vì chỉ có vị trí này khác biệt hoàn toàn, không bị nhầm lẫn với bất kì vị trí nào còn lại.

- Chọn các đặc trưng kỹ thuật làm biến độc lập.

Chia dữ liệu:

- Tách dữ liệu thành tập huấn luyện và tập kiểm tra (70-30).

Áp dụng: dùng 2 model **Logistic Regression Đa Lớp** và **Naive Bayes**

Kết quả:

- Với độ chính xác 43.24%, Logistic Regression cho kết quả chấp nhận được trong bối cảnh bài toán nhiều lớp (multi-class) và các vị trí thường có sự tương đồng nhất định.
- Mặc dù độ chính xác thấp, nhưng AUC lại khá cao (cả trên tập train và test). Điều này có thể chỉ ra rằng mô hình phân biệt khá tốt giữa các lớp (do AUC tính đến tất cả các lớp và không phụ thuộc vào sự phân phối các lớp), nhưng nó không phải lúc nào cũng dự đoán chính xác lớp cho từng mẫu. Một số lớp có thể bị dự đoán sai, nhưng mô hình vẫn giữ được khả năng phân biệt giữa các lớp.
- Mô hình Naive Bayes cũng được thử nghiệm để so sánh. Tuy nhiên, độ chính xác chỉ đạt 33.8%, thấp hơn Logistic Regression. Cũng giống như mô hình trên, AUC khá là (0.8574) cho thấy mô hình cũng phân biệt khá tốt giữa các lớp. Do đó, Logistic Regression được chọn làm mô hình chính để mở rộng bài toán.

2.2. Cách tiếp cận mở rộng

Chia dữ liệu:

- Tương tự, chia dữ liệu tập huấn luyện và kiểm tra: 70-30

Áp dụng Logistic Regression Đa Lớp: Xây dựng hàm dự đoán xác suất

- Trong Logistic Regression đa lớp, xác suất $P(y=k|X)$ của một điểm dữ liệu X thuộc vào lớp k được tính như sau:

$$P(y = k|X) = \frac{\exp(\beta_k^T X)}{\sum_{j=1}^K \exp(\beta_j^T X)}$$

Trong đó:

K : Tổng số lớp (vị trí trong đội bóng, ví dụ: Tiền đạo trái, Hậu vệ phải, Hậu vệ trái, ...).

X : Vector đặc trưng về kỹ thuật của cầu thủ

β_k : Vector hệ số hồi quy của lớp k

$\exp\cdot$: Hàm mũ.

Hàm này đảm bảo tổng xác suất của tất cả các lớp bằng 1 và tính khả dĩ (tức là mỗi xác suất $P(y=k|X)$ nằm trong khoảng từ 0 đến 1).

- Tính toán vector hệ số β_k :

Mô hình Logistic Regression học các tham số β_k bằng cách tối ưu hóa **hàm log-likelihood** của dữ liệu huấn luyện. Hàm log-likelihood được định nghĩa như sau:

$$\ell(\beta) = \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log P(y = k | X_i)$$

Trong đó:

N: Tổng số mẫu trong tập huấn luyện.

y_{ik} : Giá trị nhị phân (1 nếu mẫu thứ i thuộc lớp k, 0 nếu không).

$P(y=k|X_i)$: Xác suất được tính theo công thức đã nêu ở trên.

Hàm log-likelihood được tối ưu hóa thông qua các thuật toán như **Gradient Descent** hoặc **Iterative Reweighted Least Squares** để tìm ra các tham số β_k

Kết quả (Demo):

Mẫu ngẫu nhiên:

Vị trí thực tế: CAM

Lớp dự đoán chính xác: CAM với xác suất: 0.4933683

Ba lớp dự đoán nhầm với xác suất cao nhất:

CM với xác suất: 0.1965007

CB với xác suất: 0.06742653

LM với xác suất: 0.04145671

Với ví dụ demo trên thì mẫu đưa vào là thông tin của CAM. thì mô hình tính toán xác suất dự đoán đúng khá cao 0.4933683, và quan trọng hơn là top 3 vị trí xác suất dự đoán nhầm vào là CM, CB, LM. trong đó CM khá cao với 0.1965007. Cho thấy cầu thủ này có thể đá sang vị trí CM được. Với lý thuyết thực tế thì điều này khá hợp lý vì CAM với CM cũng dường như tương tự.

Từ kết quả này ta có thể nói rằng mô hình này sẽ giúp câu lạc bộ đánh giá được khả năng linh hoạt vị trí của cầu thủ nào đó. Từ đó dễ dàng đưa ra quyết định mua hơn.

Kết luận:

Phương pháp này chủ yếu về nền tảng toán học và thông tin xác suất hữu ích, giúp hỗ trợ các quyết định tuyển dụng và bố trí chiến thuật dựa trên dữ liệu.

Mô hình cung cấp xác suất thay vì chỉ dự đoán nhãn, giúp phân tích sâu hơn về khả năng đa nhiệm của cầu thủ. Và nó làm khá tốt, nhưng cụ thể về việc đánh giá thì chưa, chỉ dựa trên lý thuyết xác suất và toán học. Nên đây chỉ được xem như là một phần mở rộng cho bài toán dự đoán vị trí.

3. Dự đoán overall các biến chỉ số kỹ thuật- theo từng vị trí.

Mục tiêu: Xây dựng mô hình hồi quy để dự đoán biến chỉ số Overall dựa trên các biến chỉ số kỹ thuật khác.

Phương pháp:

1. **Phân chia vị trí:** Thủ môn (GK) và cầu thủ phía trên (unGK) dựa vào biến position.

2. **Lựa chọn biến kỹ thuật ban đầu:**

+ GK: gk_diving, gk_handling, gk_positioning, gk_reflexes, gk_kicking

+ unGK: tất cả các biến kỹ thuật (trừ 5 biến kỹ thuật gk_)

3. **Thực hiện quy trình:**

(1) Kiểm tra đa cộng tuyến

```
m_GK <- lm(overall ~ gk_diving + gk_handling + gk_positioning + gk_reflexes + gk_kicking, gk_data)
vif(m_GK)
```

```
##      gk_diving      gk_handling gk_positioning      gk_reflexes      gk_kicking
##      6.417563      4.608270      5.115614      6.363458      2.324669
```

1 trong 2 biến gk_diving và gk_reflexes gây ra hiện tượng đa cộng tuyến. ta lựa chọn bỏ đi biến gk_diving

```
m_GK <- lm(overall ~ gk_handling + gk_positioning + gk_reflexes + gk_kicking, gk_data)
vif(m_GK)
```

```
##      gk_handling gk_positioning      gk_reflexes      gk_kicking
##      4.482894      5.001887      3.778529      2.296927
```

Đối với GK, mô hình cơ bản với 5 biến gk_ thì sẽ có hiện tượng đa cộng tuyến, nên ta chọn 1 trong 2 biến có chỉ số >5 để loại bỏ, ở đây quyết định bỏ đi biến gk_diving. Sau khi loại bỏ biến gk_diving, thì đã loại bỏ được hiện tượng đa cộng tuyến

```
m_un_GK <- lm(overall ~ ., tech_data)
vif(m_un_GK)
```

```
##      weak_foot      height      weight      crossing
##      1.130138      1.294326      2.626519      3.348438
##      finishing heading_accuracy short_passing      volleys
##      7.057846      2.721405      6.428416      4.323175
##      dribbling      curve      fk_accuracy      long_passing
##      6.838996      4.472184      3.475158      5.016713
##      ball_control acceleration sprint_speed      agility
##      7.504988      5.803704      4.627689      3.748033
##      reactions      balance      shot_power      jumping
##      3.337259      3.149748      3.981182      1.450476
##      stamina      strength      long_shots      aggression
##      1.817281      3.518872      5.892590      2.523963
##      interceptions positioning      vision      penalties
##      9.011422      4.965905      4.659523      2.944017
##      composure      marking standing_tackle sliding_tackle
##      3.199517      4.741031      20.177523      17.184783
```

Đối với unGK, ta kiểm tra đa cộng tuyến với tất cả các biến kỹ thuật. Ta loại bỏ các biến gây ra đa cộng tuyến.

```
m_un_GK <- lm(overall ~ . -standing_tackle -finishing -interceptions -ball_control, tech_data)
vif(m_un_GK)
```

```
##      weak_foot      height      weight      crossing
##      1.127203      1.293506      2.623270      3.325664
##      heading_accuracy short_passing      volleys      dribbling
##      2.696789      5.581122      4.120567      5.315870
##      curve      fk_accuracy      long_passing      acceleration
##      4.454843      3.458634      4.976529      5.800793
##      sprint_speed      agility      reactions      balance
##      4.608518      3.725811      3.186331      3.148193
##      shot_power      jumping      stamina      strength
##      3.924330      1.446215      1.797631      3.499356
##      long_shots      aggression positioning      vision
##      5.444921      2.449296      4.549269      4.620684
##      penalties      composure      marking      sliding_tackle
##      2.846229      3.122956      4.321043      5.479022
```

Sau khi loại bỏ các biến có chỉ số vif >5, hiện tượng đa cộng tuyến được xử lý.

(2) Lựa chọn mô hình

- Sử dụng hồi quy từng bước hỗn hợp để tìm tập con tốt nhất

```
out_subset_m_GK <- regsubsets(x = overall ~ gk_handling + gk_positioning + gk_reflexes + gk_kicking,
                             data = gk_data,
                             nvmax = 4,
                             method = "exhaustive")
sum_out_subset_m_GK <- summary(out_subset_m_GK)
sum_out_subset_m_GK$cp
```

```
## [1] 10170.1433 2151.2902 238.7864 5.0000
```

Đối với GK, thì tập biến con là 4 biến được chọn sau khi loại bỏ đa cộng tuyến.

```
out_subset_m_un_GK <- regsubsets(x = overall ~ . -standing_tackle -finishing -interceptions -ball_control,
                                data = tech_data,
                                nvmax = 28,
                                method = "exhaustive")
sum_out_subset_m_un_GK <- summary(out_subset_m_un_GK)
sum_out_subset_m_un_GK$cp
```

```
## [1] 14538.66075 7493.57016 5696.32276 3297.11990 1979.33038 1329.15659
## [7] 1093.41623 845.79088 688.89313 553.61751 422.47198 322.92711
## [13] 262.98354 210.71553 159.03385 116.80096 91.39614 72.59737
## [19] 59.58237 48.91908 40.83849 32.89465 29.11778 26.92969
## [25] 25.39239 26.19920 27.00669 29.00000
```

Xem tập biến con tốt nhất

```
sum_out_subset_m_un_GK$which[which.min(sum_out_subset_m_un_GK$cp),]
```

```
## (Intercept)      weak_foot      height      weight
##          TRUE          TRUE          TRUE          TRUE
## crossing heading_accuracy short_passing volleys
##          TRUE          TRUE          TRUE          FALSE
## dribbling      curve      fk_accuracy long_passing
##          TRUE          TRUE          TRUE          TRUE
## acceleration sprint_speed agility reactions
##          TRUE          TRUE          TRUE          TRUE
## balance      shot_power      jumping      stamina
##          TRUE          TRUE          FALSE          TRUE
## strength long_shots aggression positioning
##          TRUE          TRUE          FALSE          TRUE
## vision      penalties composure marking
##          TRUE          TRUE          TRUE          TRUE
## sliding_tackle
##          TRUE
```

Đối với unGK, tập biến con tốt nhất gồm 25 biến chỉ số kỹ thuật.

(3) Chẩn đoán mô hình

- Kiểm tra tính tuyến tính
- Kiểm tra đồng nhất phương sai
- Kiểm tra outliers

(4) Mở rộng mô hình

- Sử dụng mô hình GLM

```
m_GK_GLM <- glm(overall ~ gk_handling + gk_positioning + gk_reflexes + gk_kicking,
                data = gk_data,
                family = Gamma(link = "identity"))
m_GK_2 <- lm(overall ~ gk_handling + gk_positioning + gk_reflexes + gk_kicking,
             data = gk_data)
```

```
m_un_GK_GLM <- glm(overall ~ . -standing_tackle -finishing -interceptions -ball_control -volleys -aggression -jumping,
                  data = tech_data,
                  family = Gamma(link = "identity"))
m_un_GK_2 <- lm(overall ~ . -standing_tackle -finishing -interceptions -ball_control -volleys -aggression -jumping,
               data = tech_data)
```

(5) Đánh giá mô hình

- Sử dụng chỉ số RMSE, R2_score để đánh giá mô hình

Kết quả:

```
result_GK_2 <- evaluate_model(m_GK_2, train_data, test_data, "overall")
```

```
## Test results  
## RMSE: 0.8709585  
## R2_score: 0.9863036
```

```
result_GK_3 <- evaluate_model(m_GK_GLM, train_data, test_data, "overall")
```

```
## Test results  
## RMSE: 0.8713742  
## R2_score: 0.9862906
```

Kết quả dự đoán chỉ số Overall cho vị trí thủ môn có R2_score cao cho thấy mô hình tuyến tính hoạt động tốt.

```
result_un_GK_2 <- evaluate_model(m_un_GK_2, train_data, test_data, "overall")
```

```
## Test results  
## RMSE: 2.256067  
## R2_score: 0.8885828
```

```
result_un_GK_3 <- evaluate_model(m_un_GK_GLM, train_data, test_data, "overall")
```

```
## Test results  
## RMSE: 2.256761  
## R2_score: 0.8885141
```

Kết quả dự đoán chỉ số Overall cho vị trí unGK có R2_score cũng tương đối cao cho thấy kết quả khá tốt.

Nhận xét: Với bài toán dự đoán chỉ số Overall cho các vị trí thi đấu của các cầu thủ dựa trên các biến chỉ số kỹ thuật, sử dụng mô hình Linear Regression cơ bản và mô hình GLM mở rộng cho kết quả khá tốt. Việc dự đoán chỉ số này được ứng dụng để đánh giá tổng quát sơ bộ về chất lượng cầu thủ. Chỉ số Overall cũng có thể là biến để ước tính tổng chi phí mà CLB có thể bỏ ra để sử dụng tốt cầu thủ, phù hợp với ngân sách và định hướng của CLB.

4. Dự đoán sự tiềm năng của cầu thủ

4.1. Cách tiếp cận 1: Chia potential thành 3 nhóm

Mục tiêu: Xây dựng mô hình dự đoán tiềm năng của cầu thủ dựa trên các biến số quan sát được.

Phương pháp:

1. **Phân loại tiềm năng:** Tiềm năng của cầu thủ (biến potential) được phân loại thành 3 nhóm dựa trên điểm z-score:
 - Nhóm 1: $z\text{-score} < -0.43$
 - Nhóm 2: $-0.43 \leq z\text{-score} \leq 0.43$

- Nhóm 3: $z\text{-score} > 0.43$
- 2. **Lựa chọn biến đầu vào:** Tính toán hệ số tương quan giữa các biến số với `potential_class` và lựa chọn các biến có hệ số tương quan lớn hơn 0.3. Các biến được chọn bao gồm: `age`, `overall`, `wage`, và `release_clause`.
- 3. **Xây dựng mô hình:** Sử dụng mô hình hồi quy đa thức (multinom) để dự đoán `potential_class` dựa trên các biến được chọn.
- 4. **Đánh giá mô hình:** Sử dụng confusion matrix và các chỉ số đánh giá như Accuracy, Kappa, Macro_F1 để đánh giá hiệu quả của mô hình.

Kết quả:

- Mô hình hồi quy đa thức đạt được Accuracy là 0.79 và Kappa là 0.69, cho thấy khả năng dự đoán tiềm năng của mô hình là khá tốt.
- Ma trận nhầm lẫn cho thấy mô hình dự đoán khá tốt, đặc biệt là cho nhóm tiềm năng thấp (1) và cao (3). Tuy nhiên, có sự nhầm lẫn đáng kể giữa nhóm tiềm năng trung bình (2) với hai nhóm còn lại.
- Các chỉ số Precision và Recall cho từng nhóm tiềm năng cũng đạt được giá trị cao, cho thấy mô hình có khả năng phân loại cầu thủ vào các nhóm tiềm năng một cách chính xác.

Nhận xét:

- Việc phân loại tiềm năng thành 3 nhóm giúp đơn giản hóa bài toán và tăng khả năng dự đoán của mô hình.
- Lựa chọn các biến đầu vào dựa trên hệ số tương quan giúp loại bỏ các biến không quan trọng và giảm nguy cơ overfitting.
- Mô hình hồi quy đa thức là một lựa chọn phù hợp cho bài toán phân loại với nhiều lớp.

Ứng dụng:

- Mô hình dự đoán tiềm năng có thể được sử dụng để hỗ trợ các câu lạc bộ trong việc tuyển chọn và phát triển cầu thủ trẻ.
- Các nhà quản lý có thể sử dụng mô hình để xác định các cầu thủ có tiềm năng phát triển cao và đầu tư vào việc đào tạo và phát triển họ.

- Mô hình cũng có thể được sử dụng để đánh giá giá trị của cầu thủ trên thị trường chuyển nhượng.

4.2. Cách tiếp cận 2: Chia potential thành 2 nhóm

Mục tiêu: Xây dựng mô hình dự đoán tiềm năng của cầu thủ trong dữ liệu FIFA, phân loại cầu thủ thành:

- High Potential (1): Những cầu thủ có tiềm năng lớn hơn hoặc bằng giá trị trung bình của cột *potential*.
- Not High Potential (0): Những cầu thủ có tiềm năng nhỏ hơn giá trị trung bình.

Phương pháp:

1. Xử lý dữ liệu

- Tính giá trị trung bình của cột *potential* để làm ngưỡng phân loại.
- Gán nhãn nhị phân (1 hoặc 0) dựa trên ngưỡng này.
- Kiểm tra phân phối nhãn để đảm bảo dữ liệu cân bằng và phù hợp cho bài toán phân loại.

2. Phân tích tương quan

- Tính toán tương quan giữa các biến số (age, value, wage) để đánh giá mối quan hệ tuyến tính.

3. Xây dựng mô hình

- Sử dụng hồi quy logistic để phân loại.
- Các biến giải thích: age (tuổi), value (giá trị thị trường), wage (mức lương).

4. Đánh giá mô hình

- Dữ liệu được chia thành:
 - **Tập huấn luyện (70%)** để xây dựng mô hình.
 - **Tập kiểm tra (30%)** để đánh giá hiệu suất mô hình.
- Các chỉ số đánh giá: AUC, ma trận nhầm lẫn, độ chính xác (*Accuracy*), độ nhạy (*Sensitivity*), và độ đặc hiệu (*Specificity*).

5. Trực quan hóa

- Vẽ đường cong ROC để so sánh hiệu quả trên tập huấn luyện và kiểm tra.

Kết quả:

Phân bố nhãn

- High Potential (1): 7494 cầu thủ.
- Not High Potential (0): 9149 cầu thủ.

Xây dựng mô hình hồi quy logistic

Kết quả ước lượng hệ số:

- Tuổi (age): Ảnh hưởng tiêu cực, tức cầu thủ trẻ hơn có nhiều khả năng thuộc nhóm High Potential.
- Giá trị (value): Ảnh hưởng tích cực, cầu thủ có giá trị cao hơn có khả năng cao thuộc nhóm High Potential.
- Mức lương (wage): Cầu thủ có lương cao hơn cũng thuộc nhóm High Potential.

Hiệu quả mô hình

- Tập huấn luyện: AUC đạt 0.9576 (rất tốt).
- Tập kiểm tra: AUC đạt 0.9543, chứng minh mô hình không bị overfitting

Ma trận nhầm lẫn trên tập kiểm tra:

- Độ chính xác (Accuracy): 89.24%.
- 95% CI : (0.8872, 0.9037): mô hình có độ chính xác (0.8835, 0.9009)
- Độ nhạy (Sensitivity): 93.57%, nhận diện tốt nhóm Not High Potential.
- Độ đặc hiệu (Specificity): 84.07%, nhận diện khá tốt nhóm High Potential.
- Kappa: 0.7817, mức độ phù hợp cao.

Trực quan hóa:

- Cả hai đường cong đều có AUC cao, thể hiện khả năng phân loại tốt và ổn định.

Nhận xét:

- Hồi quy logistic là phương pháp phù hợp trong bài toán phân loại này, với AUC cao (>0.95).
- Các biến giải thích (age, value, wage) đều có ý nghĩa quan trọng trong việc dự đoán tiềm năng của cầu thủ.
- Độ chính xác cao, AUC vượt trội và ma trận nhầm lẫn cho thấy mô hình có thể áp dụng tốt cho dữ liệu thực tế.

V. Phần kết

Qua quá trình thực hiện đồ án "Sports Data Analysis", nhóm đã ứng dụng thành công các phương pháp phân tích dữ liệu thống kê và học máy vào thực tiễn. Dựa trên bộ dữ liệu chi tiết về cầu thủ bóng đá toàn cầu, nhóm đã:

- Xử lý và làm sạch dữ liệu để đảm bảo tính chính xác và đáng tin cậy cho các phân tích tiếp theo.
- Khám phá và phân tích mối quan hệ giữa các biến, cung cấp những hiểu biết sâu sắc về các yếu tố ảnh hưởng đến giá trị cầu thủ.
- Xây dựng các mô hình dự đoán hiệu quả, như dự đoán giá trị chuyển nhượng, vị trí thi đấu, chỉ số tổng quan, và tiềm năng phát triển của cầu thủ.

Kết quả đạt được đã minh chứng cho tính ứng dụng của các phương pháp thống kê và học máy trong việc giải quyết các bài toán thực tế trong lĩnh vực thể thao. Những phát hiện và mô hình từ dự án không chỉ hỗ trợ các quyết định chiến lược cho câu lạc bộ bóng đá mà còn mở ra tiềm năng áp dụng rộng rãi hơn trong việc quản lý và phát triển cầu thủ.

Bên cạnh những thành công, nhóm cũng nhận thấy một số hạn chế trong việc xử lý dữ liệu và xây dựng mô hình, ví dụ như vấn đề mất cân đối dữ liệu hoặc hiệu quả dự đoán chưa tối ưu ở một số bài toán cụ thể. Đây sẽ là định hướng để cải thiện trong các nghiên cứu và ứng dụng tương lai.

Nhìn chung, đồ án đã mang lại cho nhóm những kiến thức và kinh nghiệm quý báu, đồng thời khẳng định vai trò quan trọng của dữ liệu và phân tích trong việc nâng cao hiệu quả quản lý và ra quyết định trong lĩnh vực thể thao.